FINAL PROJECT · DEMO DAY

BlackEye: Dual-Engine Fraud Detection with Explainable Decisions

كشف الاحتيال المالي لحظياً بمحركين وقرارات قابلة للتفسير

Dataset: Sparkov · LightGBM + IsolationForest · Holdout PR-AUC 0.960

BUSINESS PROBLEM

Stopping Fraud in Real Time Without Blocking Good Customers

Goal

كشف الاحتيال في الزمن الحقيقي بزمن استجابة (Latency) أقل من 100 ms.

Challenge

تمثّل الـ False Positives نحو 19% من تكلفة الاحتيال، وتزعج العملاء الشرعيين.

Solution

محركان (Supervised + Anomaly) مع طبقة دمج Fusion تقرّر / APPROVE / STEP-UP BLOCK، مع تفسير XAI لكل قرار.

إثبات الزمن الحقيقي: متوسط زمن تقييم المعاملة الواحدة (Engine 1 + Engine 2 + TreeSHAP، بدون حساب الخصائص) أقل من حد الـ SLA.

`~XX.X ms mean latency (< 100 ms SLA)`

DATASET & COLLECTION

Dataset Description and Source

Source

معاملات بطاقات مُولَّدة اصطناعياً من Sparkov (Kaggle fraud-detection)، في ملفَّي `fraudTrain.csv` و`fraudTest.csv`.

Size

Train: 1,102,173، وValidation: 194,502، وHoldout: 555,719 معاملة.

Class Imbalance

نسبة الاحتيال 0.58% في Validation مقابل 0.386% في Holdout (≈ 1 : 258).

DATA CLEANING

Cleaning and Data Quality Checks

```
# refu.py — drop leakage / IDs
df.drop(columns=["Unnamed: 0",
  "trans_num","first","last",
  "street","unix_time"])
# split.py — PII / raw coords
cc_num, merchant, city, zip, job,
dob, lat, long, merch_lat/long
```

Quality Checks (st.py)

فحص Missing values، وCardinality، وClass imbalance، وOutliers (IQR, k=1.5)، مع فحص زمني للبطاقات.

Outlier Decision

إبقاء المعاملات الشاذة (Outliers) لأنها إشارة الاحتيال وليست أخطاء؛ فلا حذف ولا Clipping للقيم الخام.

EXPLORATORY ANALYSIS

What the EDA Revealed

Class Imbalance

مقياس Accuracy مضلِّل، لذلك نعتمد PR-AUC (المرجع العشوائي = معدل الاحتيال).

Merchant Category

حذف category يُنزل PR-AUC من 0.9847 إلى 0.9326؛ فرق حقيقي.

State

حذف state لا يغيّر الأداء (0.9851، ضمن الضوضاء)، فأُسقط 51 عموداً.

DATA PREPROCESSING

Encoding, Splitting and Scaling

```
# split.py
sort_values("txn_datetime")
train = first 85% of fraudTrain
validation = last 15% of fraudTrain
holdout = fraudTest (never tuned)
get_dummies(state, category, gender)
StandardScaler.fit(train only)
```

Chronological Split

نستخدم تقسيماً زمنياً بدل Random split، لمنع تسريب سلوك المستقبل لنفس البطاقة.

86 → 35 → 31 Features

بعد Ablation (إسقاط state) أصبحت 35 خاصية، ثم 31 خاصية للإنتاج باستبعاد `age` و`gender` و`prior_txn_count`.

FEATURE ENGINEERING

Behavioral Features in refu.py

```
# prior history only (no self-leakage)
prior_sum = amt.groupby(cust).cumsum() - amt
amount_deviation_score =
  (amt - prior_mean)/(prior_std + 1e-3)
geo_velocity_proxy =
  distance_from_home_km /
  (time_since_last_txn_hrs + 0.001)
rolling("1h" / "24h") count, sum
```

Amount Deviation

الخاصيتان `amount_deviation_score` و`amt_to_prior_mean` تقارنان المبلغ بتاريخ البطاقة السابق فقط.

Velocity and Geo

ثلاث خصائص للسرعة والموقع: `merchant_velocity_kmh`، و`dist_from_prev_txn_km`، و`geo_velocity_proxy`.

Rolling Windows

عدد المعاملات والإنفاق في آخر 1h و24h (Rolling Windows)، بدون المعاملة الحالية.

MACHINE LEARNING MODELS

Two Engines and a Fusion Layer

Engine 1 · LightGBM

نموذج Supervised مع Platt Calibration وBagging على 3 seeds، وتفسير TreeSHAP لكل قرار، ومقارنة مع Logistic Regression.

Engine 2 · IsolationForest

يعمل بدون labels (100 trees) كشبكة أمان للأنماط الجديدة (Zero-day).

Fusion and Routing

$p = 1 - (1-p_{sup})(1-\lambda \cdot h(a))$ حيث a_0

$\lambda = 0.30$ و0.999 الـ Anomaly وحده يصل إلى STEP-UP فقط. العتبات: STEP-UP ≥ 0.0476 و BLOCK ≥ 0.5.

إثبات تجريبي (Zero-Day): نحذف احتيال فئة تجار واحدة من التدريب ونختبر على هذه الفئة فقط. عند ينخفض Recall لـ Engine 1 وحده إلى [XX.X%]، ويعيده IsolationForest + Fusion إلى [XX.X%]. داخل التوزيع لا يوجد مكسب (−0.0003 PR-AUC)، وهنا تظهر قيمة Engine 2.

`[Zero-Day Recall Lift: +XX.X%]`

MODEL EVALUATION

Metrics and Model Comparison

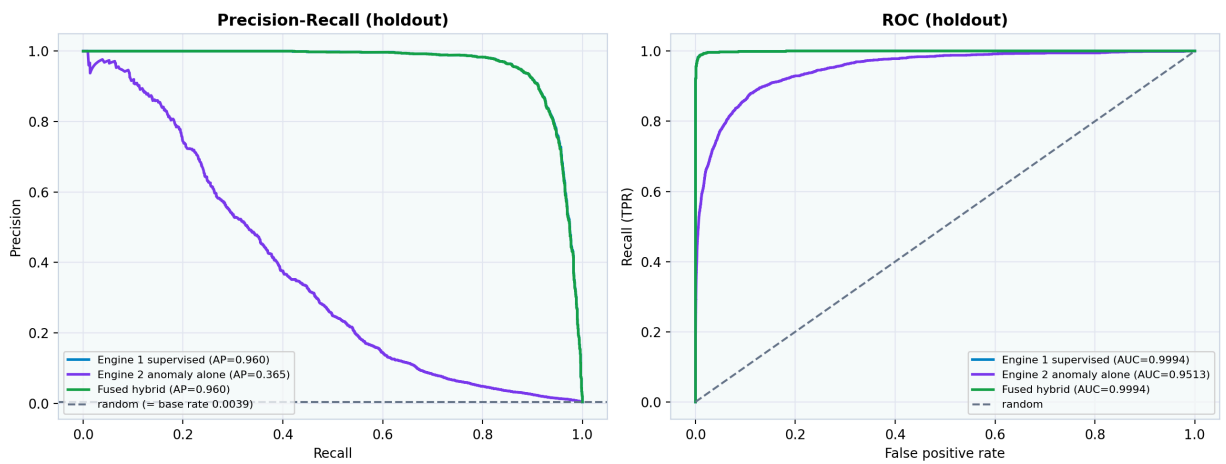


fig3_pr_roc.png · Holdout

ROC-AUC	PR-AUC	Model
0.9997	0.9847	LightGBM (all features) · Val
0.9998	0.9858	LightGBM tuned + bagged · Val
0.9649	0.5773	Logistic Regression · Val
0.9994	**0.9598**	**Engine 1 · Holdout**
0.9513	0.3651	Engine 2 alone · Holdout
0.9994	**0.9595**	**Fused · Holdout**

Reading the Result

الـ Tuning على Validation (+0.0012) ضمن الضوضاء. على Holdout يعطي الـ Fusion فرقاً قدره 0.0003− مقابل Engine 1، وهو داخل فاصل الثقة (CI: 0.9538 – 0.9628)؛ فلا مكسب داخل التوزيع، وقيمة Engine 2 مقصودة للأنماط الجديدة.

EXPLAINABILITY & CALIBRATION

Why the Model Decides: TreeSHAP and Calibration

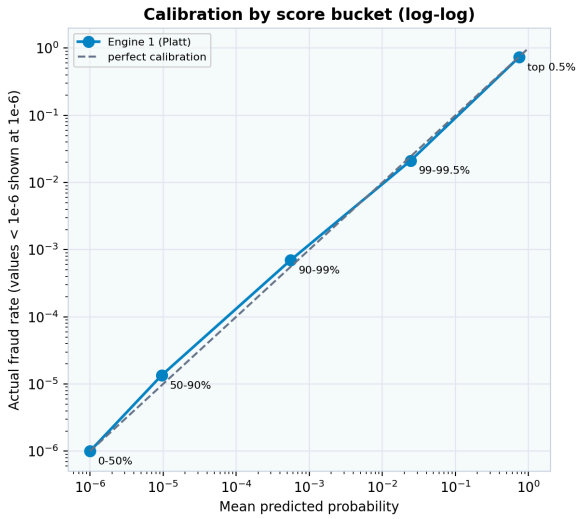


fig6_calibration.png

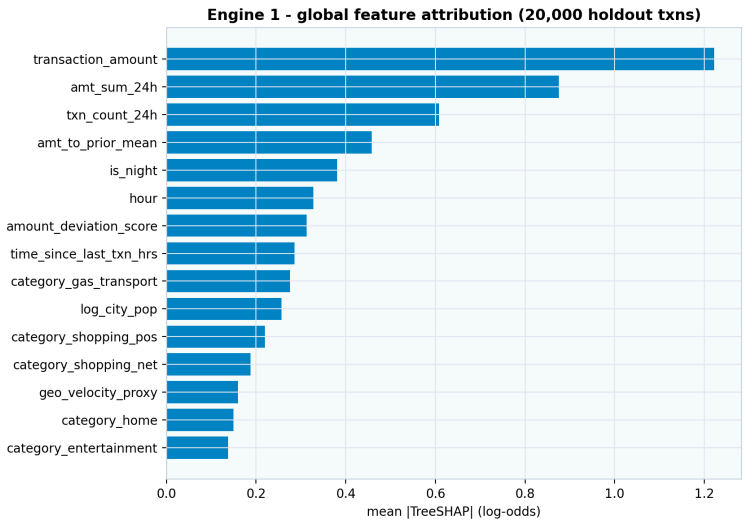


fig8_feature_importance.png

Top Global Features

`amt_sum_24h (0.88)` `transaction_amount (1.22)` `amt_to_prior_mean (0.46)` `txn_count_24h (0.61)`

متوسط |TreeSHAP| بوحدة log-odds على عيّنة من 20,000 معاملة من Holdout.

Calibration

في أعلى 0.5% من الـ scores: الاحتمال المتوقع 0.745 والفعلي 0.737. في الشريحة 99–99.5% الاحتمال المتوقع 0.0245 مقابل الفعلي 0.0212.

Per-Decision XAI

كل قرار يُسجَّل مع أهم العوامل الرافعة والخافضة للخطر في سجل مُسلسل بالـ hash (Audit Trail).

RESULTS & BUSINESS INSIGHTS

Results in Business Terms

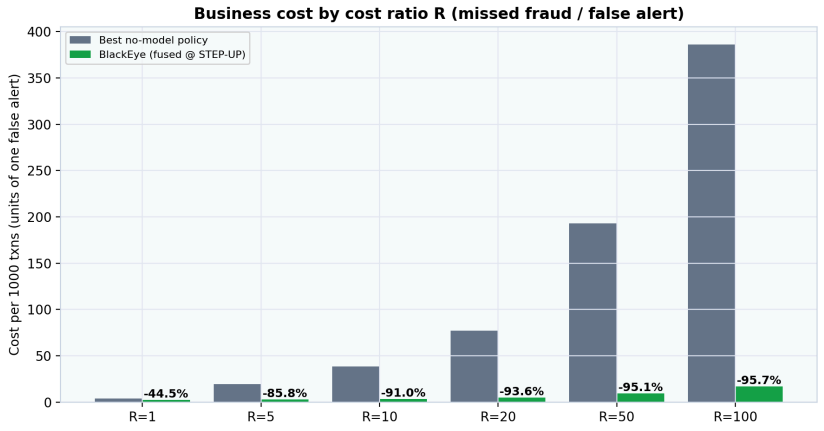


fig7_cost_by_R.png · cost per 1000 txns

SLA: زمن تقييم المعاملة مع TreeSHAP.

`~XX.X ms mean latency (< 100 ms SLA)`

Alerts and Recall

5.71 alerts لكل 1,000 معاملة عند STEP-UP،
ويلتقط 96.2% من الاحتيال (2,063 من 2,145).

BLOCK Precision

عند BLOCK: Precision 94.3% وRecall
88.2%، بمعدل 3.61 قرار لكل 1,000 معاملة.

Business Value

توفير 93.6% من التكلفة عند R = 20، و95.7%
عند R = 100، مقابل أفضل سياسة بلا نموذج (no-model policy).

552,466 Legit · Not flagged	**1,108** Legit · Flagged
82 Fraud · Missed	**2,063** Fraud · Caught

Holdout · Fused @ STEP-UP ≥ 0.0476 · n = 555,719

LIMITATIONS

Limitations

Synthetic Data

بيانات Sparkov مُولَّدة بقواعد، فالأداء العالي لا يمثّل أداء الإنتاج.

Distribution Shift

نسبة الاحتيال 0.58% في Validation مقابل 0.386% في Holdout، واختيرت الـ Thresholds على Validation.

Not Covered

لا يوجد Device fingerprint ولا مستفيد جديد (New beneficiary)، والـ Zero-day محاكاة بفئات التجار فقط.

FUTURE WORK

Future Work

Real Data

إعادة ضبط Platt، وa_0، وλ، والـ Thresholds على بيانات شبيهة بالإنتاج.

Governance and Monitoring

مراقبة الـ Drift، وسجل قرارات مُسلسل بالـ hash، وإدارة إصدارات النموذج (Model Versioning).

Integration

ربط AML وeKYC وأنظمة إدارة الحالات (Case Management)، وميزات الجهاز والمستفيد، مع حلقة تغذية راجعة من المحللين.

Q&A

Thank You

شكراً — جاهز لأسئلتكم

blackeye_engine.py · train_models.py · demo_day_eval.py