Project Review 2 • Data Understanding & Feature Engineering

Milestone 2

Data Understanding, Cleaning & Leakage-Free Feature Engineering

تحليل جودة بيانات المعاملات المصرفية، معالجة التعددية العالية، منع تسريب البيانات المستقبلي (Data Leakage)، وبناء ميزات سلوكية تراكمية.

Pipeline: Zero Data Leakage **Scripts: st.py & refu.py** **Dataset: bank_fraud.csv**

DATASET OVERVIEW & ARCHITECTURE

هيكل البيانات ومعمارية المعالجة

Input File

`bank_fraud.csv`

Output File

`engineered_data.csv`

Target Column

`is_fraud / isFraud`

1. Diagnostic Pipeline (`st.py`)

فحص القيم المفقودة، التكرارات، التعددية العالية (Cardinality)، الشواذ، وعدم توازن الفئات تلقائياً.

2. Transformation Pipeline (`refu.py`)

إسقاط أعمدة التسريب، الترتيب الزمني الدقيق لكل عميل، وإنشاء 4 ميزات سلوكية مركبة.

```python
# st.py — Auto-detect target & setup
import pandas as pd
import numpy as np

df = pd.read_csv('bank_fraud.csv')
N = len(df)

TARGET_CANDIDATES = ['isFraud', 'is_fraud', 'Fraud']
target_col = next((c for c in TARGET_CANDIDATES if c in df.columns),
None)
```

فحص القيم المفقودة والتكرارات (Missing & Duplicates)

```python
# st.py — Missing Values Detection
missing = pd.DataFrame({
  'missing_count': df.isnull().sum(),
  'missing_pct': (df.isnull().sum() / N * 100).round(2)
}).query('missing_count > 0')

print(missing if not missing.empty else "None")
```

Quality Metric	Result	Action Taken
Missing Values	rows (0.0%) 0	لا يتطلب أي استكمال أو تعويض (Imputation)
Duplicate Rows	rows (0.0%) 0	سلامة كاملة للفرادة السجلية
Data Types Integrity	Validated	تحويل الوقت والتاريخ لـ Datetime

النتيجة: خلو البيانات التام من المفقودات يمنح العينة موثوقية عالية لحساب المعادلات المتقدمة دون إدخال انحياز افتراضي.

CATEGORICAL FEATURE ANALYSIS

أنواع البيانات واكتشاف التعددية العالية (High-Cardinality)

```python
# st.py — Cardinality & High-Card Flag
dtype_summary = pd.DataFrame({
  'dtype': df.dtypes.astype(str),
  'unique_count': df.nunique(),
  'unique_pct': (df.nunique() / N * 100).round(3)
}).sort_values('unique_count', ascending=False)

high_card = dtype_summary[(dtype_summary['dtype'] == 'object') &
                          (dtype_summary['unique_pct'] > 50)]
```

High-Cardinality Detection (> 50%)

تم رصد أعمدة فئوية ذات قيم فريدة تتجاوز 50% مثل `customer_id` و `transaction_id`.

Avoid Naive One-Hot Encoding

تطبيق One-Hot Encoding على هذه المتغيرات يؤدي لتضخم أبعاد البيانات (Curse of Dimensionality)، لذا يتم تجميعها حاسوبياً أو إسقاط المفرط منها.

TARGET DISTRIBUTION

تحليل عدم توازن الفئات (Class Imbalance)

Target Variable

`is_fraud / isFraud`

High Imbalance

تداخل ضئيل جداً لنسبة الاحتيال مقابل الهيمنة العظمى للمعاملات الطبيعية.

Evaluation Metric Strategy

استبعاد مقياس Accuracy التقليدي لأنه يعطي انطباعاً مضللاً، والاعتماد على مقاييس `PR-AUC` و `F1-Score`.

```
# st.py — Class Imbalance & Ratio
counts = df[target_col].value_counts()
pct = (counts / N * 100).round(4)
maj, minr = counts.max(), counts.min()
print(f"Imbalance ratio = {maj/minr:.1f} : 1")
```

OUTLIER DIAGNOSTICS

كشف الشواذ: تقاطع IQR مع Z-Score (|z| > 3)

```
# st.py — IQR & Z-score Cross Check
q1, q3 = df[col].quantile([0.25, 0.75])
iqr = q3 - q1
lo, hi = q1 - 1.5 * iqr, q3 + 1.5 * iqr
n_out = int(((df[col] < lo) | (df[col] > hi)).sum())

# Cross-check top 5 features with Z-score
z_out = int((np.abs(zscore(df[col].dropna())) > 3).sum())
```

1. IQR Method (k = 1.5)

تحديد الحدود باستخدام الربيعيات ($IQR = Q3 - Q1$). ممتازة للتوزيعات الملتوية كالمبالغ والمسافات.

2. Z-Score Cross-Check (|z| > 3)

تدقيق الميزات الخمس الأكثر شذوذاً للتأكد من القراءات الحادة جداً عبر الانحراف المعياري.

CRITICAL CLEANING DECISION

القيم الشاذة: نمط احتيالي (Signal) أم أخطاء؟

```python
# st.py — Fraud-Conditional Outlier Skew
if target_col:
  for col in outlier_df.head(5)['feature']:
    q1, q3 = df[col].quantile([0.25, 0.75]); iqr = q3 - q1
    lo, hi = q1 - 1.5*iqr, q3 + 1.5*iqr
    rate = df.groupby(target_col)[col].apply(
      lambda s: ((s < lo) | (s > hi)).mean() * 100
    )
    print(f"{col} Outlier Rate: {dict(rate.round(2))}")
```

Outlier Rate by Class

أظهر التحليل المشروط أن معدل الشذوذ يرتفع بشكل مكثف فقط داخل الفئة المحتالة (`is_fraud = 1`).

Decision: Retain Outliers

القيم الشاذة هي جوهر إشارة الاحتيال. حذفها أو تقليمها (Clipping) يؤدي لتدمير قدرة النموذج التنبؤية.

DATA LEAKAGE CONTROL (REFU.PY)

استراتيجية منع تسريب البيانات (Zero Data Leakage)

```python
# refu.py — Leakage Drop & Chronological Sort
df = df.drop(columns=['transaction_id', 'fraud_type'], errors='ignore')
df['_row_id'] = np.arange(len(df))

# Sort chronologically per customer
df['txn_datetime'] = pd.to_datetime(df['transaction_date'] + ' ' +
df['transaction_time'])
df = df.sort_values(['customer_id', 'txn_datetime'])
```

1. Drop Leakage Columns

إسقاط `transaction_id` و `fraud_type` فوراً لمنع الغش الخفي.

2. Chronological Ordering

الترتيب حسب `customer_id` والتاريخ `txn_datetime` للحفاظ على تسلسل الزمن.

3. Prior-History Statistics

استثناء الصف الحالي عند حساب المتوسط السلوكي لمنع التسريب الذاتي.

الميزات السلوكية المشتقة في `refu.py`

```
# refu.py — Vectorized Feature Calculations
# 1. Prior-history Z-score (excl. current row)
prior_n = df.groupby(cust).cumcount()
prior_sum = amt.groupby(cust).cumsum() - amt
df['amount_deviation_score'] = ((amt - prior_mean) / (prior_std + 1e-
3)).fillna(0)

# 2. Geo Velocity Proxy
df['geo_velocity_proxy'] = df['distance_from_home_km'] /
(df['time_since_last_txn_hrs'] + 0.001)

# 3. Failed Intl Interaction & Balance Drain
df['failed_intl_interaction'] = df['failed_attempts'] *
df['is_international']
df['balance_drain_ratio'] = df['transaction_amount'] /
(df['account_balance'] + 0.001)
```

`amount_deviation_score`

انحراف مبلغ المعاملة عن تاريخ العميل السابق فقط.

`geo_velocity_proxy`

نسبة المسافة الجغرافية إلى الوقت لافتراض السرعة المستحيلة.

`failed_intl_interaction`

تفاعل المحاولات الفاشلة مع الصفة الدولية للمعاملة.

`balance_drain_ratio`

مبلغ العملية مقسوماً على رصيد الحساب المتاح.

BEFORE VS AFTER COMPARISON

مقارنة حالة البيانات قبل وبعد المعالجة

Pipeline Criteria	(bank_fraud.csv) Before Cleaning	(engineered_data.csv) After Engineering
Data Leakage Risk	High (fraud_type & IDs present)	Zero Leakage Verified
Temporal Sequence	Unordered / Unsorted Records	Chronologically Sorted per Customer
Behavioral Features	Raw Features Only	Engineered Behavioral Features Added 4
ML Pipeline Readiness	Not Ready for Modeling	Ready for Module 3 (EDA & Models) 100%

MILESTONE 2 DELIVERABLES

قائمة المخرجات وتوثيق المجموعات (Checklist)



1. Engineered Dataset

البيانات المنظفة والمجهزة ومحفوظة بملف:

`engineered_data.csv`



2. Executable Scripts

أكواد معالجة قابلة للتكرار (Reproducible):

`st.py` `refu.py`



3. GitHub Repository

رفع الشفرات والوثائق كاملة للمراجعة المباشرة خلال Demo Day.

Zero Data Leakage • ML Pipeline Ready

Thank You — Q&A Session

تمت المعالجة بنجاح، والبيانات جاهزة تماماً للانتقال إلى مرحلة النمذجة والتصوير البياني في Module 3.

`engineered_data.csv` `refu.py` `st.py`